Práctica 1: Preparación y preprocesamiento para textos

1. Descripción del corpus

Para la realización de la práctica se ha utilizado el conjunto de datos Amazon Reviews 2023, seleccionando la categoría Home_and_Kitchen, que contiene un total de 67.409.944 reseñas.

Debido al elevado volumen de datos de esta categoría y a las limitaciones de los recursos computacionales disponibles, se decidió trabajar con un subconjunto de 15.000 reseñas. Esta reducción permite almacenar, procesar y analizar el corpus de forma viable durante la práctica sin necesidad de trabajar con la totalidad del conjunto de datos.

Las reseñas se clasifican en tres categorías de sentimiento a partir de su *rating*: negative, para ratings inferiores a 3; neutral, para ratings iguales a 3; y positive, para ratings superiores a 3. Durante el análisis previo de los datos se comprobó que los ratings presentes en el conjunto de datos toman únicamente los valores numéricos enteros representados como decimales 1.0, 2.0, 3.0, 4.0 y 5.0, sin valores intermedios como 2.5 o 3.5.

2. Preparación y organización del corpus

Para obtener un corpus equilibrado entre las tres categorías de sentimiento y mantener un tamaño manejable, se estableció un límite configurable de reseñas por categoría mediante el parámetro `--max-per-class`, cuyo valor por defecto es 5.000. Las reseñas se leen secuencialmente (lectura en *streaming*) y, cuando una categoría alcanza este límite, las siguientes reseñas pertenecientes a ella se descartan. Esta estrategia constituye una solución preliminar y determinista, ya que la selección depende del orden de lectura y puede limitar la representatividad y el alcance del corpus.

Los archivos originales se obtienen en formato JSONL comprimido con gzip y se procesan línea por línea, sin necesidad de descomprimirlos previamente en disco.

El contenido textual de cada documento se construye a partir del título y el cuerpo de la reseña, ya que consideramos que el título puede aportar información. Cuando ambos están disponibles, se combinan mediante un punto y un espacio; si sólo está disponible uno de ellos, se conserva el existente. Cuando ambos están vacíos, la reseña se descarta.

Durante la construcción del corpus también se controlan los duplicados. Un mismo usuario puede publicar más de una reseña sobre el mismo producto, por lo que estas se conservan cuando su contenido textual es diferente. En cambio, cuando coinciden el usuario, el producto y el texto, la reseña se considera duplicada y no vuelve a incorporarse al corpus.

Para identificar cada reseña almacenada se genera un identificador propio a partir del identificador del usuario (user_id), el identificador del producto (parent_asin) y el timestamp de la reseña. La incorporación del timestamp permite distinguir diferentes reseñas realizadas por un mismo usuario sobre un mismo producto en momentos distintos. Cuando el timestamp no está disponible, se utiliza

como alternativa el número de reseñas seleccionadas hasta ese momento para la polaridad correspondiente.

Una vez seleccionadas las reseñas, se recopilan los identificadores parent_asin de sus productos en un conjunto sin duplicados. A continuación, se recorre el archivo de metadatos para recuperar únicamente la información de esos productos, evitando cargar todos los metadatos en memoria.

Se eliminan de los metadatos las imágenes y vídeos, al no aportar información textual relevante para la práctica. El resto de información relevante se conserva en documentos individuales en formato JSON, dentro de la carpeta correspondiente a su categoría (negative, neutral o positive). Esta organización permite posteriormente acceder a los documentos tanto de manera individual como agrupados por categoría mediante el *corpus reader*.

3. Acceso al corpus

Se implementó la clase `AmazonCorpusReader`, que hereda de `CorpusReader` y `CategorizedCorpusReader` de NLTK.

El Reader permite consultar el corpus a tres niveles:

- **Corpus completo**, sin especificar ningún documento ni categoría.
- **Categoría**, mediante el parámetro `categories`.
- **Documento o conjunto de documentos**, mediante el parámetro `fileids`.

Se implementaron las siguientes funciones principales de acceso:

- **docs()**: devuelve los documentos completos seleccionados.
- **raw()**: devuelve el texto almacenado de las reseñas, sin aplicar el preprocesamiento del Reader.
- **rating()**: devuelve el rating de una reseña individual.
- **ratings()**: devuelve los ratings de un conjunto de reseñas.
- **paras()**: devuelve los párrafos, estructurados como oraciones tokenizadas.
- **sents()**: devuelve las oraciones como listas de tokens.
- **words()**: devuelve los tokens del conjunto de reseñas seleccionado.

De esta forma, por ejemplo, es posible obtener las palabras de todo el corpus, de una única categoría o de un documento concreto mediante:

```
corpus.words()
corpus.words(categories="positive")
corpus.words(fileids="positive/documento.json")
```

La función `raw()` permite conservar siempre el acceso al texto almacenado durante la preparación del corpus, independientemente de las operaciones de preprocesamiento activadas.

4. Operaciones de preprocesamiento

El preprocesamiento se ha integrado en `AmazonCorpusReader` mediante diferentes opciones

configurables. El objetivo es poder activar o desactivar cada operación según las necesidades de las prácticas posteriores, evitando modificar de forma irreversible los documentos originales.

Se han implementado las siguientes operaciones:

- **Eliminación de HTML:** eliminación de etiquetas HTML y conversión de entidades HTML.
- **Eliminación de elementos vacíos:** filtrado de elementos vacíos durante el procesamiento del texto.
- **Eliminación de emojis:** permite eliminar caracteres correspondientes a los rangos Unicode de emojis contemplados en la implementación.
- **Eliminación de caracteres especiales:** permite eliminar símbolos especiales conservando la puntuación básica necesaria para el análisis textual.
- **Normalización de caracteres repetidos:** permite reducir secuencias de tres o más caracteres repetidos, por ejemplo, *soooo* a *soo*.
- **Conversión a minúsculas:** permite normalizar el texto convirtiendo los caracteres a minúsculas.
- **Normalización de espacios:** eliminación de espacios y tabulaciones redundantes, aplicada independientemente de la configuración de las flags.
- **Eliminación de stopwords:** permite eliminar las palabras vacías del inglés utilizando la lista proporcionada por NLTK. Se conservan las negaciones *not*, *no* y *nor*, incluso cuando se activa esta operación, porque pueden modificar la polaridad de una opinión y su eliminación podría alterar el significado de las reseñas.

Estas operaciones, salvo la normalización de espacios, se controlan mediante flags. Esto permite adaptar el preprocesamiento a las necesidades de las tareas posteriores. Por ejemplo, en una tarea de análisis de sentimiento, los emojis, los signos de puntuación o las repeticiones de caracteres pueden contener información sobre la intensidad o polaridad de una opinión.

El texto almacenado permanece disponible mediante `raw()`, por lo que el preprocesamiento no modifica los documentos guardados en el corpus.

Para comprobar el funcionamiento del preprocesamiento, se realizaron pruebas utilizando dos configuraciones: una con todas las flags desactivadas (`False`) y otra con todas activadas (`True`). La normalización de espacios se aplica en ambos casos. Esta comparación permite observar el efecto conjunto de las operaciones sobre la representación textual de las reseñas. Las salidas completas de ambas configuraciones se incluyen en el Anexo.

5. Estadísticas del corpus

Para obtener una descripción estadística del corpus, se ha implementado el método `describe()`, que permite calcular estadísticas de los documentos seleccionados. Mediante los parámetros `fileids` y `categories`, es posible analizar un documento individual, un conjunto de documentos, una categoría concreta o el corpus completo.

La función calcula el número de documentos, su distribución por categorías, las reseñas con valoración y texto, la distribución de ratings, el número de párrafos, oraciones y tokens, el tamaño del vocabulario y el número de usuarios y productos distintos. Para calcular las estadísticas textuales se

reutilizan los métodos `paras()`, `sents()` y `words()` del lector.

Para calcular el tamaño del vocabulario, se consideran únicamente los tokens que contienen caracteres alfanuméricos y se convierten a minúsculas, evitando distinguir palabras que únicamente difieren en su capitalización.

El corpus final contiene 15.000 reseñas, distribuidas de forma equilibrada entre las tres categorías de sentimiento, con 5.000 documentos negativos, 5.000 neutrales y 5.000 positivos. Todas las reseñas contienen texto y valoración. Se identificaron 2.661 usuarios y 13.697 productos distintos.

La distribución de valoraciones es la siguiente:

Rating	**Número de reseñas**
1	3.035
2	1.965
3	5.000
4	1.007
5	3.993
Total	**15.000**

Para analizar el efecto del preprocesamiento, se compararon las estadísticas obtenidas con todas las flags desactivadas y activadas:

Estadística	**Todas `False`**	**Todas `True`**
Documentos	15.000	15.000
Párrafos	15.000	15.000
Oraciones	81.522	85.094
Tokens	1.257.224	689.722
Tamaño del vocabulario	25.227	22.034
Usuarios distintos	2.661	2.661
Productos distintos	13.697	13.697

Al activar todas las operaciones de preprocesamiento, el número de tokens disminuye aproximadamente un 45,1 % y el tamaño del vocabulario un 12,7 %. Esta reducción refleja el efecto conjunto de las operaciones aplicadas, especialmente la eliminación de stopwords y la normalización del texto, aunque la comparación no permite cuantificar la contribución individual de cada una.

Por otro lado, el número de oraciones aumenta aproximadamente un 4,4 %. Esta diferencia puede explicarse por los cambios que el preprocesamiento introduce en el texto antes de aplicar la segmentación de oraciones de NLTK. Por tanto, el número de oraciones detectadas depende de la configuración utilizada y no debe interpretarse como un aumento de las oraciones presentes en las reseñas originales.

En las pruebas realizadas, el número de documentos, párrafos, usuarios y productos permanece constante entre ambas configuraciones. Las operaciones de preprocesamiento no modifican los documentos ni sus metadatos almacenados, aunque podrían afectar al número de párrafos detectados en otros corpus.

En conjunto, los resultados muestran que las operaciones de preprocesamiento pueden modificar considerablemente las características lingüísticas del corpus. Por ello, la configuración utilizada debe elegirse en función de los objetivos del análisis posterior, especialmente en tareas de clasificación de sentimiento, donde determinados elementos del texto pueden aportar información relevante.

Las salidas completas del método `describe()` y de las pruebas de acceso al corpus para ambas configuraciones se recogen en el Anexo.

6. Conclusiones

Se ha construido un corpus equilibrado de 15.000 reseñas de Amazon, organizado según tres categorías de sentimiento. La estructura desarrollada permite acceder de forma flexible tanto a documentos individuales como a categorías o al corpus completo y trabajar con diferentes niveles de representación: texto sin preprocesamiento, párrafos, oraciones y tokens.

La incorporación de un preprocesamiento configurable permite reutilizar el corpus en tareas posteriores de PLN sin modificar los documentos almacenados. La comparación entre las configuraciones con todas las flags activadas y desactivadas ha permitido comprobar cómo estas operaciones afectan al número de tokens, al tamaño del vocabulario y a la segmentación de oraciones.

Además, las estadísticas obtenidas permiten caracterizar el tamaño del corpus y comprobar su distribución equilibrada entre las tres categorías definidas.

7. Anexo: Pruebas de ejecución

En este anexo se recogen las salidas de ejecución de las pruebas realizadas sobre el corpus de 15.000 reseñas, utilizando dos configuraciones de preprocesamiento: todas las flags desactivadas (`False`) y todas activadas (`True`).

7.1. Pruebas con todas las flags desactivadas (`False`)

En esta configuración no se aplican las operaciones opcionales de preprocesamiento, aunque se mantiene la normalización de espacios.

Configuración utilizada:

```
REMOVE_HTML = False
REMOVE_EMPTY = False
REMOVE_EMOJIS = False
REMOVE_SPECIAL_CHARS = False
NORMALIZE_REPEATED_CHARS = False
REMOVE_STOPWORDS = False
LOWERCASE = False
```

Salida de ejecución:

```
Categorías:
['negative', 'neutral', 'positive']

Número total de documentos (reviews):
15000

Documentos por categoría:
negative: 5000
neutral: 5000
positive: 5000

--- PRUEBA DE UN DOCUMENTO ---

Fileid:
positive/AE2DWV6OPSOUHDZEZQBC2MRYAOXA_B07PY5DN8P_1561328344034.json

Categoría:
['positive']
```

```
Rating:
5.0

Texto en crudo:
Cozy, and for the price this was a great buy!. For the price this was a
great buy! I bought the 1.5 inch and it was very cozy.

Párrafos:
[[['Cozy', ',', 'and', 'for', 'the', 'price', 'this', 'was', 'a', 'great',
'buy', '!', '.'], ['For', 'the', 'price', 'this', 'was', 'a', 'great',
'buy', '!'], ['I', 'bought', 'the', '1.5', 'inch', 'and', 'it', 'was',
'very', 'cozy', '.']]]

Oraciones:
[['Cozy', ',', 'and', 'for', 'the', 'price', 'this', 'was', 'a', 'great',
'buy', '!', '.'], ['For', 'the', 'price', 'this', 'was', 'a', 'great',
'buy', '!'], ['I', 'bought', 'the', '1.5', 'inch', 'and', 'it', 'was',
'very', 'cozy', '.']]

Palabras:
['Cozy', ',', 'and', 'for', 'the', 'price', 'this', 'was', 'a', 'great',
'buy', '!', '.', 'For', 'the', 'price', 'this', 'was', 'a', 'great', 'buy',
'!', 'I', 'bought', 'the', '1.5', 'inch', 'and', 'it', 'was', 'very',
'cozy', '.']

--- PRUEBA POR CATEGORÍA ---

Número de palabras positivas:
342870

Número de oraciones neutrales:
29523

Primeros 10 ratings negativos:
[2.0, 1.0, 1.0, 1.0, 1.0, 1.0, 2.0, 1.0, 2.0, 1.0]

--- PRUEBA DEL CORPUS COMPLETO ---

Número total de palabras:
1257224

Número total de oraciones:
81522

Número total de párrafos:
```

```
15000

Número total de ratings:
15000

--- ESTADÍSTICAS DEL CORPUS ---

Número total de documentos:
15000

Documentos por categoría:
negative: 5000
neutral: 5000
positive: 5000

Reseñas con rating:
15000

Reseñas con texto:
15000

Reseñas con rating y texto:
15000

Distribución de ratings:
1.0: 3035
2.0: 1965
3.0: 5000
4.0: 1007
5.0: 3993

Número de párrafos:
15000

Número de oraciones:
81522

Número total de palabras/tokens:
1257224

Número de palabras distintas (vocabulario):
25227

Número de usuarios distintos:
2661
```

```
Número de productos distintos:
13697

--- DESCRIBE: RESEÑAS POSITIVAS ---

Número total de documentos positivos:
5000

Reseñas con rating:
5000

Reseñas con texto:
5000

Reseñas con rating y texto:
5000

Número de párrafos:
5000

Número de oraciones:
26437

Número total de palabras/tokens:
342870

Número de palabras distintas (vocabulario):
11344

Número de usuarios distintos:
326

Número de productos distintos:
4809

--- DESCRIBE: 10 DOCUMENTOS ---
File IDs de los primeros 10 documentos:
['negative/AE25NQAZI3725GZIL5FS52ZIKWKQ_B00H4P4ZBO_1453523941000.json',
'negative/AE25NQAZI3725GZIL5FS52ZIKWKQ_B07JGKK5M5_1562427159928.json',
'negative/AE25NQAZI3725GZIL5FS52ZIKWKQ_B0BZQZXHWP_1510599919790.json',
'negative/AE2CJPQPEGCIDJKZZRYDSVRV46SA_B004OF968O_1493389988000.json',
'negative/AE2CJPQPEGCIDJKZZRYDSVRV46SA_B00P9UC004_1521055721867.json',
'negative/AE2CJPQPEGCIDJKZZRYDSVRV46SA_B0148477Y0_1492282057000.json',
'negative/AE2CJPQPEGCIDJKZZRYDSVRV46SA_B081B65WT8_1591466996903.json',
```

```
'negative/AE2CJPQPEGCIDJKZZRYDSVRV46SA_B08G7Y67GH_1617298313281.json',
'negative/AE2CJPQPEGCIDJKZZRYDSVRV46SA_B08NVKYLGV_1521054740535.json',
'negative/AE2CO6MCKFITWP2QMMS2HZAVXD7A_B0B1PWZPF4_1676044734636.json']

Número total de documentos:
10

Documentos por categoría:
negative: 10
neutral: 0
positive: 0

Reseñas con rating:
10

Reseñas con texto:
10

Reseñas con rating y texto:
10

Distribución de ratings:
1.0: 7
2.0: 3

Número de párrafos:
10

Número de oraciones:
52

Número total de palabras/tokens:
735

Número de palabras distintas (vocabulario):
310

Número de usuarios distintos:
3

Número de productos distintos:
10
```

7.2. Pruebas con todas las flags activadas (True)

En esta configuración se aplican todas las operaciones opcionales de preprocesamiento implementadas en el lector.

Configuración utilizada:

```
REMOVE_HTML = True
REMOVE_EMPTY = True
REMOVE_EMOJIS = True
REMOVE_SPECIAL_CHARS = True
NORMALIZE_REPEATED_CHARS = True
REMOVE_STOPWORDS = True
LOWERCASE = True
```

Salida de ejecución:

```
Categorías:
['negative', 'neutral', 'positive']

Número total de documentos (reviews):
15000

Documentos por categoría:
negative: 5000
neutral: 5000
positive: 5000

--- PRUEBA DE UN DOCUMENTO ---

Fileid:
positive/AE2DWV6OPSOUHDZEZQBC2MRYAOXA_B07PY5DN8P_1561328344034.json

Categoría:
['positive']

Rating:
5.0

Texto en crudo:
Cozy, and for the price this was a great buy!. For the price this was a
great buy! I bought the 1.5 inch and it was very cozy.

Párrafos:
[[['cozy', ',', 'price', 'great', 'buy', '!', '.'], ['price', 'great',
'buy', '!'], ['bought', '1.5', 'inch', 'cozy', '.']]]
```

```
Oraciones:
[['cozy', ',', 'price', 'great', 'buy', '!', '.'], ['price', 'great',
'buy', '!'], ['bought', '1.5', 'inch', 'cozy', '.']]

Palabras:
['cozy', ',', 'price', 'great', 'buy', '!', '.', 'price', 'great', 'buy',
'!', 'bought', '1.5', 'inch', 'cozy', '.']

--- PRUEBA POR CATEGORÍA ---

Número de palabras positivas:
197380

Número de oraciones neutrales:
31639

Primeros 10 ratings negativos:
[2.0, 1.0, 1.0, 1.0, 1.0, 1.0, 2.0, 1.0, 2.0, 1.0]

--- PRUEBA DEL CORPUS COMPLETO ---

Número total de palabras:
689722

Número total de oraciones:
85094

Número total de párrafos:
15000

Número total de ratings:
15000

--- ESTADÍSTICAS DEL CORPUS ---

Número total de documentos:
15000

Documentos por categoría:
negative: 5000
neutral: 5000
positive: 5000

Reseñas con rating:
```

```
15000

Reseñas con texto:
15000

Reseñas con rating y texto:
15000

Distribución de ratings:
1.0: 3035
2.0: 1965
3.0: 5000
4.0: 1007
5.0: 3993

Número de párrafos:
15000

Número de oraciones:
85094

Número total de palabras/tokens:
689722

Número de palabras distintas (vocabulario):
22034

Número de usuarios distintos:
2661

Número de productos distintos:
13697

--- DESCRIBE: RESEÑAS POSITIVAS ---

Número total de documentos positivos:
5000

Reseñas con rating:
5000

Reseñas con texto:
5000

Reseñas con rating y texto:
```

```
5000

Número de párrafos:
5000

Número de oraciones:
26180

Número total de palabras/tokens:
197380

Número de palabras distintas (vocabulario):
10606

Número de usuarios distintos:
326

Número de productos distintos:
4809

--- DESCRIBE: 10 DOCUMENTOS ---
File IDs de los primeros 10 documentos:
['negative/AE25NQAZI3725GZIL5FS52ZIKWKQ_B00H4P4ZBO_1453523941000.json',
'negative/AE25NQAZI3725GZIL5FS52ZIKWKQ_B07JGKK5M5_1562427159928.json',
'negative/AE25NQAZI3725GZIL5FS52ZIKWKQ_B0BZQZXHWP_1510599919790.json',
'negative/AE2CJPQPEGCIDJKZZRYDSVRV46SA_B004OF968O_1493389988000.json',
'negative/AE2CJPQPEGCIDJKZZRYDSVRV46SA_B00P9UC004_1521055721867.json',
'negative/AE2CJPQPEGCIDJKZZRYDSVRV46SA_B0148477Y0_1492282057000.json',
'negative/AE2CJPQPEGCIDJKZZRYDSVRV46SA_B081B65WT8_1591466996903.json',
'negative/AE2CJPQPEGCIDJKZZRYDSVRV46SA_B08G7Y67GH_1617298313281.json',
'negative/AE2CJPQPEGCIDJKZZRYDSVRV46SA_B08NVKYLGV_1521054740535.json',
'negative/AE2CO6MCKFITWP2QMMS2HZAVXD7A_B0B1PWZPF4_1676044734636.json']

Número total de documentos:
10

Documentos por categoría:
negative: 10
neutral: 0
positive: 0

Reseñas con rating:
10

Reseñas con texto:
```

```
10

Reseñas con rating y texto:
10

Distribución de ratings:
1.0: 7
2.0: 3

Número de párrafos:
10

Número de oraciones:
51

Número total de palabras/tokens:
420

Número de palabras distintas (vocabulario):
238

Número de usuarios distintos:
3

Número de productos distintos:
10
```